你提出的改法（**先由 G 生成两个调制超参数，去调制 A^{rgb}, A^{ir}，再得到一个 $Y \in \mathbb{R}^{B\times 1\times d}$**）是成立的，而且很像高光谱融合里常见的 **modulation / FiLM / dynamic weighting** 思路。

下面给你一个"完整方案"，满足你所有约束：

- text 作 query（桥梁）
- 不加显式对齐损失（只靠检测损失反向优化）
- 最终只产生 **1 个 token 的 Y**（避免 C 倍膨胀）
- 还能**恢复成与 RGB 特征图同尺寸**的注入项（注意：这一步不能简单 `reshape(Y)`，需要一个"从 token 回到空间"的展开操作；我会给你一个最干净的闭环公式）

方案 C′：Agreement → MLP → 双超参数调制注意力 → 单 token 输出 → 空间回注入

Step 0：输入与 text 原型

在 neck 某一尺度：

$$F^{rgb}, F^{ir} \in \mathbb{R}^{B\times D\times H\times W}, \quad N = H\cdot W$$

展平为 token：

$$X^{rgb}, X^{ir} \in \mathbb{R}^{B\times N\times D}$$

准备冻结 text 类别原型（或文本编码器输出）：

$$T \in \mathbb{R}^{C\times d_t}$$

Step 1：Text-as-Query 得到两路注意力 A^{rgb}, A^{ir}

构造 Query（共享）：

$$Q = \mathrm{Norm}(TW_q) \in \mathbb{R}^{C\times d_k}$$

构造 Key/Value：

$$K^m = X^m W_k^m \in \mathbb{R}^{B\times N\times d_k}, \quad V^m = X^m W_v^m \in \mathbb{R}^{B\times N\times d_v}, \quad m \in \{rgb, ir\}$$

Cross-attn 得到两路注意力：

$$A^m = \mathrm{Softmax}_N\left(\frac{Q(K^m)^\top}{\sqrt{d_k}}\right) \in \mathbb{R}^{B\times C\times N}$$

> 到这里为止仍然有 C（因为你需要"同一 text 类别下的注意力图"来比较一致性），但我们马上把它**压回 1**。

Step 2：从 A^{rgb}, A^{ir} 计算一致性 G（仍是 $B\times C$）

对每个 query 类别 c，取空间注意力向量：

$$a_{b,c}^{rgb} = A_{b,c,:}^{rgb} \in \mathbb{R}^N, \quad a_{b,c}^{ir} = A_{b,c,:}^{ir} \in \mathbb{R}^N$$

一致性（cosine）：

$$g_{b,c} = \frac{\langle a_{b,c}^{rgb}, a_{b,c}^{ir}\rangle}{\|a_{b,c}^{rgb}\|_2 \|a_{b,c}^{ir}\|_2 + \varepsilon} \in [-1, 1]$$

得到：

$$G \in \mathbb{R}^{B\times C}$$

Step 3：用 MLP 把 G 压缩为两个超参数（你想要的"调制操作"）

这里有两种你可以选的"压缩方式"。我建议用 **3.1**（更稳、更符合"避免 C 放大"）。

3.1（推荐）先把 G 做统计汇聚，再 MLP 输出两个标量

计算几个统计量（不依赖 C 的维度大小）：

$$u_b = \left[\mathrm{mean}(G_b),\ \max(G_b),\ \mathrm{std}(G_b)\right] \in \mathbb{R}^3$$

MLP 输出两条调制超参数：

$$[\eta_b^{rgb}, \eta_b^{ir}] = \mathrm{MLP}(u_b) \in \mathbb{R}^2$$

并做归一化（避免数值发散）：

$$[\lambda_b^{rgb}, \lambda_b^{ir}] = \mathrm{Softmax}([\eta_b^{rgb}, \eta_b^{ir}]) \quad \Rightarrow \quad \lambda^{rgb}, \lambda^{ir} \in (0,1),\ \lambda^{rgb} + \lambda^{ir} = 1$$

Step 4：用两个超参数去"调制" A^{rgb}, A^{ir}，并把 C 压成 1 个注意力图

关键点：你要从 $B \times C \times N$ 得到 $B \times 1 \times N$。

一个非常自然的做法是：先用 G 生成一个 **类权重** w，把 C 个 query 的注意力**加权汇聚**成"单张空间注意力图"。

先把一致性 G 变成类权重（softmax over C）：

$$w_{b,:} = \mathrm{Softmax}\left(\frac{G_{b,:}}{\tau_g}\right) \in \mathbb{R}^C, \quad \sum_c w_{b,c} = 1$$

对两路注意力分别做类维度汇聚（得到单注意力图）：

$$\bar{A}^{rgb}_{b,1,:} = \sum_{c=1}^{C} w_{b,c}\, A^{rgb}_{b,c,:} \in \mathbb{R}^N$$

$$\bar{A}^{ir}_{b,1,:} = \sum_{c=1}^{C} w_{b,c}\, A^{ir}_{b,c,:} \in \mathbb{R}^N$$

然后用你 MLP 生成的两超参数做调制融合（你说的"调制操作"）：

$$\tilde{A} = \lambda^{rgb} \odot \bar{A}^{rgb} + \lambda^{ir} \odot \bar{A}^{ir} \in \mathbb{R}^{B \times 1 \times N}$$

最后把它重新归一化成标准注意力分布（对 N 做归一）：

$$A^{fuse} = \frac{\tilde{A}}{\sum_{n=1}^{N} \tilde{A}_{:,:,n} + \varepsilon} \in \mathbb{R}^{B \times 1 \times N}$$

到这里，C **已经被你完全压掉**，只剩一张融合注意力图 A^{fuse}。

注意维度：

- $(A^{fuse})^\top \in \mathbb{R}^{B\times N\times 1}$
- $Y \in \mathbb{R}^{B\times 1\times d_v}$

因此：

$$X^{inj} \in \mathbb{R}^{B\times N\times d_v}$$

然后 reshape 回空间：

$$F^{inj} = \mathrm{reshape}(X^{inj}) \in \mathbb{R}^{B\times d_v\times H\times W}$$

再用一个 1×1 conv 投回通道数 D 并残差注入（RGB 主干、IR 辅助，符合你"IR 可能有问题"的设定）：

$$\Delta F = \psi(F^{inj}) \in \mathbb{R}^{B\times D\times H\times W}$$

$$\boxed{F^{out} = F^{rgb} + \Delta F}$$

你要的"综合相加公式"版本（把核心串成一条主线）

为了满足你希望"一条相加公式展示"的风格，我给你一个论文里可用的紧凑表达（省略中间的归一化符号）：

$$\boxed{F^{out} = F^{rgb} + \psi\Big(\mathrm{reshape}\Big((A^{fuse})^\top\,(A^{fuse}(\lambda^{rgb}V^{rgb} + \lambda^{ir}V^{ir}))\Big)\Big)}$$

其中：

$$A^{fuse} = \mathrm{Norm}_N\Big(\lambda^{rgb}\sum_c w_c A_c^{rgb} + \lambda^{ir}\sum_c w_c A_c^{ir}\Big),\quad w = \mathrm{Softmax}\Big(\frac{G}{\tau_g}\Big),\quad [\lambda^{rgb},\lambda^{ir}] = \mathrm{Softmax}(\mathrm{MLP}(\mathrm{Pool}(G)))$$