2. 输入与符号

在某个尺度（或多尺度可扩展）：

- RGB 特征 token：

$$X^{rgb} \in \mathbb{R}^{B\times N\times D}, \quad N = H\cdot W$$

- IR（可信）特征 token：

$$X^{ir} \in \mathbb{R}^{B\times N\times D}$$

- 文本类别原型（冻结或弱训练）：

$$T = [t_1; \dots ; t_C] \in \mathbb{R}^{C\times d_t}, \quad \|t_c\|_2 = 1$$

可学习投影：

- $W_{ir\to t} \in \mathbb{R}^{D\times d_t}$
- $W_q \in \mathbb{R}^{d_t\times d_k}$
- $W_k \in \mathbb{R}^{D\times d_k}$
- $W_v \in \mathbb{R}^{D\times d_v}$
- $\mathrm{MLP} : \mathbb{R}^{d_v} \to \mathbb{R}^{d_t}$

超参：

- $\tau > 0$：IR→text 类权重温度
- d_k, d_v：attention 维度
- $\gamma \in (0, 1]$：视觉写入强度（可以常数，也可以由 IR 置信度自适应）

---

3. 计算流程（与你给出的公式一一对应）

Step A：IR 作为语义锚点，得到类别权重 w

1. 从 IR 得到一个全局语义向量（池化 + 投影 + 归一化）：

$$u^{ir} = \mathrm{Norm}\big(\mathrm{Pool}(X^{ir})W_{ir\to t}\big) \in \mathbb{R}^{B\times d_t}$$

- $\mathrm{Pool}(\cdot)$ 推荐用 mean pooling：$\mathrm{Pool}(X) = \frac{1}{N}\sum_{n=1}^{N} X_{:,n,:}$
- 也可用 attention pooling（更强但更重），初版建议 mean

2. 与所有类别文本原型做相似度，并 softmax 得到类别权重：

$$w = \mathrm{Softmax}\left(\frac{u^{ir}T^{\top}}{\tau}\right) \in \mathbb{R}^{B\times C}$$

解释：w 是"样本在 IR 视角下的语义分布"，它是后续所有检索/更新的锚点。

上面是对 IR 进行了处理

3. 为什么我建议你用 "IR-Guided CBAM"?

在你的任务（RGB + IR 融合）中，我们不能直接照搬原始的 CBAM，而是要做一点点**魔改**，这正是你创新的地方：

1. **对于通道注意力 (Step 1)：**
   - 让 RGB 自己做。因为 RGB 的颜色和纹理信息最丰富，它需要自己判断哪些通道有效（比如去掉因光照过曝损坏的通道）。
2. **对于空间注意力 (Step 2)：**
   - **不要用 RGB 做，要用 IR 做！**
   - 原始 CBAM 是从 Input 自己提取空间 Mask。
   - 你的方案是：**利用 IR 特征图来生成这个 Spatial Mask**，然后乘到 RGB 上。

$$X'_{rgb} = X_{rgb} + \alpha \cdot [\mathrm{ChannelAttn}(X_{rgb}) \cdot \mathrm{SpatialMask}(X_{ir})]$$

或者更简单的变体（CBAM 标准残差）：

$$X_{temp} = X_{rgb} \cdot \mathrm{ChannelAttn}(X_{rgb})$$

$$X_{final} = X_{temp} + X_{temp} \cdot \mathrm{SpatialMask}(X_{ir})$$

为什么加残差？

使用 IR-Guided CBAM 对 RGB 进行处理并进行残差

Step B：Text 作为桥梁，检索 RGB 视觉证据（Text→RGB Cross-Attention）

1. 构造 query（来自文本原型）：

$$Q = TW_q \in \mathbb{R}^{C \times d_k}$$

2. 构造 RGB 的 key/value：

$$K^{rgb} = X^{rgb} W_k \in \mathbb{R}^{B \times N \times d_k}, \quad V^{rgb} = X^{rgb} W_v \in \mathbb{R}^{B \times N \times d_v}$$

3. text→RGB cross-attention 得到每个类别的空间注意力与类别条件视觉上下文：

$$A^{rgb} = \mathrm{Softmax}_N \left(\frac{Q(K^{rgb})^\top}{\sqrt{d_k}} \right) \in \mathbb{R}^{B \times C \times N}$$

$$Y^{rgb} = A^{rgb} V^{rgb} \in \mathbb{R}^{B \times C \times d_v}$$

解释： $Y^{rgb}_{b,c,:}$ 是"类别 c 在 RGB 特征上检索到的视觉证据摘要"。

- **Step 2: 逐类别残差更新 (Class-wise Update)**
  - 不再聚合 t_{base}。直接对原始的 C 个文本原型 t_c 进行一对一更新。
  - **公式：**

$$t_c^{new} = \mathrm{Norm}(t_c + \gamma \cdot \mathrm{MLP}(Y_c^{rgb}))$$

  - 这里 MLP 将视觉维度的 Y_c^{rgb} 映射回文本维度，并作为残差加到原始文本上。
- **最终输出：** $T^{new} \in \mathbb{R}^{B \times C \times d_t}$。即 Batch 中每张图片都有自己专属的一套"被视觉微调过"的 C 个类别文本向量，用于后续 Head 的匹配。

上面两张图片，使用更新后的 IR 和经过耿新华 IR 处理的 RGB 求出 Y_{rgb}，并对 C 个 text 进行更新。